

Roadmap di Sviluppo del Progetto HERO: Indice dei Moduli

Questo è il file centrale di coordinamento per la roadmap di sviluppo del progetto **HERO (Hunger Early-warning & Risk Optimizer)**. Il piano è suddiviso in moduli autonomi e interconnessi per facilitare la gestione dei task di Data Mining & Machine Learning (DMML), Time Series Analysis (TSMDA) e Data Visualization (DVVA).

Clicca sui link sottostanti per esplorare la documentazione dettagliata, le specifiche visuali e le checklist implementative di ciascuna fase:

Indice delle Fasi di Sviluppo

■ FASE 1: Preprocessing, Armonizzazione e Gestione del Dato Mancante

- **Descrizione:** Standardizzazione demografica dei driver per 100.000 abitanti (ACLED, IDP) e imputazione spaziotemporale KNN guidata dalle coordinate geografiche.
- ■ [Checklist Implementativa - Fase 1 Tasks](#)

■ FASE 2: Approccio Statico (Cross-Sectional, Senza Sequenzialità)

- **Descrizione:** Clustering statico dei paesi (K-Means, DBSCAN, Hierarchical) e modelli predittivi supervisionati per l'IPC3+ (KNN, Decision Trees, SVM, Random Forest, XGBoost) con spiegabilità SHAP.
- ■ [Checklist Implementativa - Fase 2 Tasks](#)

■ FASE 3: Feature Engineering ed Esplorazione Time Series (Sequenzialità)

- **Descrizione:** Pattern temporali (Matrix Profile), Shapelets, feature selection **tsfresh**, DTW/NCD clustering, stazionarizzazione (test ADF) e cross-correlazioni (CCF).
- ■ [Checklist Implementativa - Fase 3 Tasks](#)

■ FASE 4: Modellazione Temporale (Inferenza e Forecast su TS)

- **Descrizione:** Classificazione traiettorie IPC3+ (Weak Supervision), forecast univariato nativo baseline, forecast multivariato VAR, diagnostica residui e Stacking Ensemble.
- ■ [Checklist Implementativa - Fase 4 Tasks](#)

■ FASE 5: Inferenza Cross-Regionale (Global Forecasting)

- **Descrizione:** Global Cluster Forecasting, Domain Adaptation / Transfer Learning spaziotemporale e spiegabilità temporale SHAP su feature **tsfresh**.

- ■ [Checklist Implementativa - Fase 5 Tasks](#)

■■ [FASE 6: Tecniche di Frontiera \(Integrazione TSMDA & DMML\)](#)

- **Descrizione:** Network Analysis classica dei mercati (NetworkX), autocorrelazione spaziale (Moran's I & LISA), TimesFM Zero-Shot forecast e DBSCAN Outlier detection.
- ■ [Checklist Implementativa - Fase 6 Tasks](#)

■ [FASE 7: A/B Testing e Benchmarking Sperimentale](#)

- **Descrizione:** Calcolo comparativo delle performance (MAE, RMSE, MAPE) e visualizzazione spider/radar chart del benchmarking.
- ■ [Checklist Implementativa - Fase 7 Tasks](#)

■■ [FASE 8: Visualizzazione Interattiva \(Data Visual Analytics\)](#)

- **Descrizione:** Dashboard web Folium/GeoPandas, ApexCharts heatmap, trend lineari/radar e il simulatore interattivo di scenario "What-If".
- ■ [Checklist Implementativa - Fase 8 Tasks](#)

■■ [FASE 9: Intervista](#)

- **Descrizione:** Idee per la intervista.
- ■ [Checklist Implementativa - Fase 9 Tasks](#)

■ [Alberatura di Archiviazione dei Risultati \(Risultati & Plot\)](#)

Tutti i codici verranno archiviati all'interno della cartella **ML/codes/**, mentre tutti i prodotti analitici (immagini, mappe, CSV intermedi e tabelle) seguiranno una rigida alberatura gerarchica all'interno di **ML/results/**:

```
ML/
  ■■■ codes/
  ■   ■■■ run_clustering.py
  ■   ■■■ [altri script di pipeline...]
  ■■■ results/
  ■■■ preprocessing/
  ■   ■■■ missingness_heatmap_before.png
  ■   ■■■ missingness_heatmap_after.png
  ■   ■■■ kde_density_control_[driver].png
  ■   ■■■ spatial_imputed_markers_map.png
  ■■■ static_inference/
  ■   ■■■ country_static_dendrogram.png
  ■   ■■■ country_static_heatmap.png
  ■   ■■■ pca_tsne_static_clusters.png
```

- ■■■■ shap_static_beeswarm_plot.png
- time_series_exploration/
 - ■■■■ 01_Statistical-Decomposition_STL.png
 - ■■■■ 02b_Compare_Series_Autocorrelation.png
 - ■■■■ 02c_Cross_Correlation_with_Target.png
 - ■■■■ 02c_Cross_Correlation_with_Target.csv
 - ■■■■ 04_Matrix_Profile_Anomalies_Discords.png
 - ■■■■ shapelet_alignments/
 - ■ ■■■■ [plot delle shapelets per provincia...]
 - ■■■■ heatmaps/
 - ■ ■■■■ global_national_dtw_heatmap.png
 - ■■■■ dendrograms/
 - ■ ■■■■ global_regions_dendrogram_features.png
 - ■ ■■■■ global_regions_dendrogram_shape.png
 - ■■■■ clustering/
 - ■ ■■■■ global_regions_pca_scatter.png
 - ■■■■ maps/
 - ■■■■ global_national_map.png
 - ■■■■ global_regions_map.png
- temporal_modeling/
 - ■■■■ 05_MultiModel_Forecast_Comparison.png
 - ■■■■ 06_Model_Residuals_Diagnostics.png
 - ■■■■ confusion_matrices/
 - ■ ■■■■ trajectory_confusion_matrix.png
 - ■■■■ forecasts/
 - ■ ■■■■ [plot dei forecast indipendenti per provincia...]
 - ■■■■ var_irf/
 - ■ ■■■■ var_impulse_response_subplots.png
 - ■■■■ stacking_weights/
 - ■■■■ stacking_weights_distribution.png
- global_forecasting/
 - ■■■■ global_actual_vs_predict.png
 - ■■■■ global_residuals_scatterplot.png
 - ■■■■ shap_temporal_beeswarm_plot.png
- frontier_techniques/
 - ■■■■ market_network_graph.png
 - ■■■■ moran_scatterplot.png
 - ■■■■ lisa_cluster_map.png
 - ■■■■ timesfm_zeroshot_forecast.png
 - ■■■■ dbscan_spatial_outliers.png
 - ■■■■ ncd_compression_heatmap.png
- benchmarking/
 - metrics_summary_table.csv
 - models_error_comparison_bar.png
 - models_performance_radar_chart.png

FASE 1: Preprocessing, Armonizzazione e Gestione del Dato Mancante

Il dataset unificato unisce fonti altamente eterogenee (IPC, ACLED, WFP, GDELT, NDVI, Rainfall). La sfida principale risiede nella presenza di missing values e nelle differenti scale delle variabili.

1. Normalizzazione e Armonizzazione Geografica e Temporale (KDD Workflow)

- **Standardizzazione dei Driver:** Per evitare sbilanciamenti causati dalla dimensione demografica dei territori, le variabili di conflitto (ACLED - eventi e vittime) e di migrazione interna (IDP - sfollati) verranno normalizzate per **100.000 abitanti** (calcolate sulla popolazione totale dell'area).
 - **Conversione IDP:** La popolazione IDP sarà espressa anche come percentuale sulla popolazione totale dell'area per rappresentare la densità dello shock.
 - **Tipi di Dati:** Ottimizzazione del consumo di memoria (conversione in `float32` per le percentuali, `category` per i codici geografici).
 - **Preservazione della Risoluzione Temporale Nativa:**
 - Il riallineamento temporale su griglia mensile uniforme (`MS`) è vincolante **solo** per le analisi e i modelli predittivi che richiedono il join diretto con la spina dorsale del target IPC.
 - Per tutti gli studi di tipo autonomo o indipendente (ad esempio l'analisi di rete dei mercati alimentari o l'anomaly detection sui prezzi e precipitazioni), **si deve mantenere la risoluzione temporale nativa non aggregata** (es. settimanale o giornaliera dei prezzi WFP, o pentadica/decalica per dati climatici) al fine di non disperdere la ricchezza informativa e catturare con massima precisione i lag temporali a breve termine e la propagazione rapida degli shock.
-

2. Gestione dei Dati Mancanti e Ricostruzione delle Serie Storiche

La ricostruzione dei dati mancanti, in particolare per la serie storica dell'IPC, adotta due logiche complementari:

A. Ricostruzione delle Serie Storiche IPC su Base Nazionale (Country-Bounded Reconstruction)

- **Logica:** Per colmare buchi temporali o ricostruire intere serie storiche dell'IPC in province povere di dati, si utilizzano le serie temporali delle altre province appartenenti allo **stesso paese**. Gli shock macroeconomici, le risposte politiche e i cicli stagionali sono fortemente coesi all'interno dei confini nazionali.
- **Metodologia:** La ricostruzione opera separando i dati per nazione (`groupby('Country')`). Se una provincia A presenta valori IPC mancanti in determinati mesi, questi vengono ricostruiti come combinazione lineare o spaziale pesata (tramite distanza geometrica o correlazione storica delle serie)

delle serie delle altre province del medesimo paese che possiedono dati completi in quegli stessi mesi. Questo garantisce la coerenza macro-regionale dei dati stimati.

B. Algoritmo `impute_missing_knn_geo_similarity`

- **Logica:** Sfrutta l'algoritmo KNN Imputer (`sklearn.impute.KNNImputer`) inserendo le coordinate spaziali (`latitude` e `longitude` standardizzate) direttamente nel calcolo delle distanze.
- **Razionale:** Le aree geograficamente contigue tendono a condividere profili climatici e dinamiche economiche simili. Includere le coordinate guida la ricerca dei "vicini" più simili, migliorando l'accuratezza dei valori imputati.
- **Sicurezza:** Gestione automatica delle colonne interamente nulle a livello di singolo gruppo (evitando crash del codice) e riduzione dinamica del numero di vicini (`n_neighbors`) in caso di campioni insufficienti.

■ Grafici e Visualizzazioni per la FASE 1

- **Missingness Heatmap (Prima vs Dopo):** Mappa di calore bidimensionale (regioni vs feature) che mostra graficamente in nero i dati mancanti prima del preprocessing e in bianco il dataset completamente popolato dopo il KNN spaziale.
- **Density plots di Controllo (Originale vs Imputato):** Grafici a curve di densità sovrapposte (KDE Plot) per ciascun driver (es. piogge, inflazione). Consente di verificare visivamente che la distribuzione probabilistica del dato imputato con KNN non presenti distorsioni o shift sistematici rispetto alla distribuzione dei dati reali osservati.
- **Mappa Spaziale delle Imputazioni:** Mappa geografica con marker colorati per evidenziare le regioni in cui è stato necessario ricorrere all'imputazione (e l'intensità/percentuale dei dati ricostruiti).

C. Definizione algoritmo per la gestione dei dati mancanti

Usare diverse metriche per la scelta dell'algoritmo giusto.

Checklist di Sviluppo - FASE 1: Preprocessing e Imputazione Spaziale

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 1**. L'obiettivo è armonizzare le scale demografiche e ricostruire i valori mancanti dei driver usando la prossimità geografica.

■ Task List

[] Task 1.1: Normalizzazione e Armonizzazione Demografica

- **Descrizione:** Scalare i conteggi crudi dei driver per renderli comparabili tra province di dimensioni demografiche diverse.
 - **Sotto-task:**
 - [] Caricare il dataset `merged_adm1_wide_knn.parquet` o `merged_adm1_wide.parquet`.
 - [] Calcolare le vittime e gli eventi ACLED ogni 100.000 abitanti: $\frac{\text{acled_events}}{\text{population}} \times 100.000$
 - [] Calcolare la popolazione IDP come percentuale sulla popolazione totale: $\frac{\text{idp_population}}{\text{population}} \times 100$
 - [] Gestire la staleness dei dati IDP: impostare a `NaN` le osservazioni IDP più vecchie di 400 giorni (`idp_staleness_days`).
-

[] Task 1.2: Ricostruzione delle Serie Storiche IPC su Base Nazionale (Country-Bounded)

- **Descrizione:** Ricostruire i valori temporali mancanti dell'IPC per una determinata provincia sfruttando le serie storiche delle province dello stesso paese.
 - **Sotto-task:**
 - [] Raggruppare il dataset per nazione (`groupby('Country')`).
 - [] Sviluppare una funzione che, per ogni provincia `SP$` con dati IPC mancanti in un mese `$t$`, identifichi le altre province del medesimo paese che possiedono dati IPC validi nello stesso mese.
 - [] Calcolare la matrice delle distanze geografiche (o correlazione storica delle variabili climatiche) tra la provincia `SP$` e le province donatrici limitrofe.
 - [] Ricostruire il valore IPC mancante al tempo `$t$` come media pesata (inversa della distanza o proporzionale alla correlazione) dei valori delle province donatrici dello stesso paese.
 - [] Validare la ricostruzione assicurando che i trend nazionali vengano rispettati e che non vi sia perdita di dinamica locale.
-

[] Task 1.3: Imputazione Spaziotemporale KNN (Geo-Similarity)

- **Descrizione:** Applicare la funzione di imputazione spaziale basata su KNN per i driver esogeni.
- **Firma della Funzione:** `python def impute_missing_knn_geo_similarity(df, target_columns, lat_col='latitude', lon_col='longitude', n_neighbors=5): """ Imputa i valori mancanti nelle colonne target usando KNN, utilizzando Latitudine e Longitudine come guida geometrica. """`
- **Sotto-task:**
 - [] Verificare la presenza di coordinate: scartare temporaneamente le righe prive di latitudine/longitudine valide (non possono guidare l'imputazione spaziale).
 - [] Isolare le feature: creare una matrice contenente `[latitude, longitude] + target_columns`.
 - [] Standardizzare le feature (`StandardScaler`): passaggio obbligatorio prima del KNN per evitare che le scale geografiche dominino quelle dei driver.
 - [] Inizializzare `KNNImputer(n_neighbors=k, weights='distance')` adattando dinamicamente `k` se il numero di righe disponibili è inferiore a `n_neighbors`.
 - [] Eseguire il fit ed inverse transform, e reinserire i valori imputati nel DataFrame originale.

[] Task 1.4: Diagnostica e Visualizzazione del Preprocessing

- **Descrizione:** Generare grafici di controllo per validare il comportamento dell'imputazione spaziale.
- **Sotto-task:**
 - [] Generare e salvare la **Missingness Heatmap** prima e dopo l'imputazione.
 - [] Tracciare i **KDE Plot** (Kernel Density Estimate) per ciascun driver per confrontare la distribuzione dei dati originali rispetto a quelli imputati.
 - [] Salvare tutti i grafici diagnostici nella cartella `ML/results/preprocessing/`.

FASE 2: Approccio Statico (Cross-Sectional, Senza Sequenzialità)

Tratta i dati collassando l'asse temporale, considerando ogni osservazione (regione in un determinato periodo) come un record indipendente ("cross-section").

Task 2.1 - Clustering dei Paesi (EDA Statica)

- **Algoritmi:** K-Means, DBSCAN, Hierarchical Clustering.
 - **Metodologia:** Calcolo dei valori medi storici standardizzati di tutti i driver per ciascun paese.
 - **Visualizzazione:** Creazione di Heatmap ordinate e dendrogrammi per raggruppare i paesi in base alla pura magnitudo delle loro crisi (es. "Paesi a forte intensità di conflitto" vs "Paesi a forte vulnerabilità climatica").
-

Task 2.2 - Inferenza su IPC in base alle Features Correnti

- **Target:** Stima della percentuale di popolazione in crisi alimentare (`phase_3plus_percentage`).
 - **Modelli:** K-Nearest Neighbors (KNN), Decision Trees, Support Vector Machines (SVM), Random Forest, XGBoost.
 - **Explainability:** Utilizzo dei plot di **Feature Importance** e **SHAP (SHapley Additive exPlanations)** per identificar e classificare quali driver esogeni (es. inflazione alimentare vs numero conflitti) esercitino il massimo impatto predittivo in logica statica.
 - **Rilevanza delle Coordinate:** Inclusione di `latitude` e `longitude` standardizzate come feature. Tramite SHAP, si quantificherà l'importanza relativa dello spazio geografico rispetto alle variabili socio-economiche e di conflitto.
-

■ Grafici e Visualizzazioni per la FASE 2

- **Dendrogramma Gerarchico Statico:** Grafico ad albero per mostrare la gerarchia di aggregazione dei paesi basata sulle medie dei driver.
- **Heatmap dei Cluster statici:** Una matrice ordinata secondo i cluster ottenuti, con i driver sulle colonne e i paesi sulle righe, colorata in base alla magnitudo normalizzata del driver (per identificare a colpo d'occhio i fattori dominanti di ciascun cluster).
- **SHAP Summary Plot (Beeswarm):** Grafico che mostra l'impatto positivo o negativo di ciascuna feature sulla predizione dell'IPC3+, con i punti colorati in base al valore alto/basso della feature. Evidenzierà visivamente la rilevanza relativa di `latitude` e `longitude` rispetto ai driver socio-economici.
- **Scatter Plot 2D (PCA / t-SNE):** Rappresentazione bidimensionale dei cluster statici di paesi, colorati per etichetta di cluster, per valutare la separabilità geometrica nello spazio ridotto.

Checklist di Sviluppo - FASE 2: Approccio Statico (Cross-Sectional)

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 2**. L'obiettivo è stabilire una baseline predittiva e descrittiva analizzando i dati in logica "cross-section" (senza memoria temporale).

■ Task List

[] Task 2.1: Clustering Statico dei Paesi (EDA Descrittiva)

- **Descrizione:** Raggruppare i paesi in base alla magnitudo media dei loro driver di crisi storici.
 - **Sotto-task:**
 - [] Aggregare il dataset calcolando la media storica di tutti i driver normalizzati (ACLED, IDP, Rainfall, NDVI, WFP) per ciascun paese.
 - [] Standardizzare la matrice risultante.
 - [] Applicare **Hierarchical Clustering** (legame Ward) per generare il dendrogramma dei paesi.
 - [] Applicare **K-Means** (e determinare il numero ottimale di cluster con il metodo del gomito / Silhouette Score).
 - [] Generare una heatmap ordinata secondo i cluster ottenuti (paesi sulle righe, driver sulle colonne) per visualizzare i pattern di crisi (es. paesi guidati da conflitto vs paesi guidati da siccità).
-

[] Task 2.2: Inferenza Statica su IPC3+ (Classificazione e Regressione)

- **Descrizione:** Addestrare modelli supervisionati per stimare il target `phase_3plus_percentage` usando solo i valori istantanei correnti dei driver.
 - **Sotto-task:**
 - [] Suddividere i dati in Train e Test set in modo stratificato o geografico (per evitare data leakage spaziale).
 - [] Configurare e addestrare i seguenti modelli:
 - [] K-Nearest Neighbors (KNN Regressor)
 - [] Decision Tree Regressor
 - [] Random Forest Regressor
 - [] XGBoost / LightGBM Regressor
 - [] Includere `latitude` e `longitude` standardizzate nel set di feature e valutarne l'effetto sulle performance.
 - [] Calcolare le metriche di accuratezza (MAE, RMSE, R^2) sul test set.
-

[] Task 2.3: Spiegabilità Statica dei Driver (Explainability)

- **Descrizione:** Estrarre il contributo delle variabili alla stima dell'IPC usando SHAP e Feature Importance classica.
- **Sotto-task:**
 - [] Estrarre l'importanza intrinseca delle feature per i modelli ad albero (Gini Importance).
 - [] Configurare `shap.TreeExplainer` per il modello XGBoost/Random Forest addestrato.
 - [] Generare e salvare lo **SHAP Summary Plot (Beeswarm)** per quantificare l'impatto positivo/negativo di ciascun driver sul target.
 - [] Analizzare visivamente la forza predittiva delle coordinate lat/lon rispetto alle variabili fisiche e socio-economiche.
 - [] Salvare i risultati in `ML/results/static_inference/`.

FASE 3: Feature Engineering ed Esplorazione Time Series (Sequenzialità)

Le osservazioni vengono trattate come sequenze temporali ordinate: $X_i = \langle x_{t1}, x_{t2}, \dots, x_{tm} \rangle$.

Task 3.1 - Anomaly Detection con Matrix Profile (Motifs & Discords)

- **Metodologia:** Calcolo del **Matrix Profile** su una finestra temporale di $m = 12$ mesi (finestra annuale classica) per le serie esogene (prezzi WFP, piogge).
 - **Obiettivo:**
 - **Motifs:** Trovare pattern ciclici o ripetitivi di incremento di vulnerabilità.
 - **Discords:** Identificare shock sistemici anomali (anomalie strutturali isolate).
 - **Identificazione Shock:** Calcolo del Z-score sui residui e classificazione come shock sistemico per deviazioni superiori a $Z > 2.0$.
-

Task 3.2 - Uso delle Shapelets (Subsequence-based Classification)

- **Metodologia:** Gli algoritmi estrarranno le "Shapelets", ovvero le sottosequenze temporali brevi e altamente discriminanti all'interno delle serie storiche dei driver.
 - **Applicazione in HERO:** Trovare una combinazione specifica (es. un incremento repentino dei prezzi alimentari WFP abbinato a un calo persistente del vigore vegetazionale NDVI per 3 mesi consecutivi) che precede storicamente l'impennata dei livelli di IPC 3+. La distanza geometrica delle nuove serie da questa Shapelet diventa la feature predittiva principale.
-

Task 3.3 - Feature-Based Clustering (tsfresh) & Dissimilarità

- **tsfresh Feature Extraction:** Generazione automatica di centinaia di feature strutturali (coefficienti di Fourier, trend lineari, picchi, autocorrelazioni) per ciascuna serie temporale.
 - **Feature Selection:** Applicazione del modulo di selezione basato su test di ipotesi di **tsfresh** per ridurre la dimensionalità e mantenere solo le feature strutturali correlate al target IPC3+.
 - **CBD (Compression-Based Dissimilarity):** Misura della dissimilarità tra serie calcolando la comprimibilità delle serie concatenate, per catturare similitudini strutturali anche in presenza di forte rumore di fondo.
-

Task 3.4 - Clustering Dinamico con DTW (Dynamic Time Warping)

- **Logica:** Allineamento flessibile dell'asse temporale. Se due province reagiscono allo stesso shock climatico o di mercato con 2 mesi di ritardo l'una rispetto all'altra, il DTW ne riconosce la somiglianza deformando il tempo.
 - **Applicazione:** Creazione di "Cluster Funzionali" di comportamento dinamico tra regioni.
-

Task 3.5 - Analisi di Stazionarietà e Differenziazione Automatica (Stazionarizzazione)

- **Logica:** I modelli temporali classici (ARIMA, VAR) richiedono che la serie storica sia stazionaria (media, varianza e struttura di autocorrelazione costanti nel tempo) per evitare regressioni spurie e stime errate.
 - **Metodologia:**
 - Applicazione del test **Augmented Dickey-Fuller (ADF)** per testare l'ipotesi nulla di non-stazionarietà.
 - **Studio tramite ACF/PACF:** Analisi visiva dei correlogrammi per diagnosticare la presenza di trend o componenti stagionali (un decadimento molto lento dell'ACF indica non-stazionarietà/trend; la presenza di picchi periodici indica stagionalità).
 - Se il test fallisce (p-value ≥ 0.05) o l'analisi ACF conferma il trend, si applica in automatico la differenziazione temporale di primo ordine ($d=1$) o di secondo ordine ($d=2$).
 - Estrazione della componente stagionale, trend e residua mediante decomposizione **STL (Seasonal-Trend Decomposition using LOESS)**.
-

Task 3.6 - Analisi di Cross-Correlazione con Lag (CCF)

- **Logica:** Misurare la relazione di lead-lag temporale tra i driver esogeni (es. anomalie delle precipitazioni o prezzi) e la risposta del target (IPC3+).
 - **Metodologia:** Calcolo della funzione di cross-correlazione (CCF) per lag compresi tra -12 (il driver precede l'IPC di 12 mesi) e $+12$ mesi per individuare indicatori anticipatori.
-

■ Grafici e Visualizzazioni per la FASE 3

I grafici di questa fase devono essere archiviati nella directory **ML/results/time_series_exploration/** (con eventuali sotto-cartelle per provincia/paese):

- **Decomposizione STL (01_Statistical_Decomposition_STL.png):** Plot a 4 pannelli (Observed, Trend, Seasonal, Residuals) per illustrare la scomposizione delle serie temporali.
- **Grafico ACF e PACF Comparativo (02b_Compare_Series_Autocorrelation.png):** Pannello doppio che confronta i correlogrammi prima e dopo il processo di stazionarizzazione (differenziazione) per confermare la rimozione di trend e stagionalità e studiare la stazionarietà.

- **Cross-Correlation Function Plot ([02c_Cross_Correlation_with_Target.png](#))**: Grafico che traccia la correlazione per lag (da -12 a +12). Evidenzia visivamente a quale lag temporale si trova la massima correlazione (early-warning signal).
- **Allineamento Time Series + Matrix Profile ([04_Matrix_Profile_Anomalies_Discords.png](#))**: Grafico a due pannelli sovrapposti. Il pannello superiore mostra la serie storica originale con gli shock evidenziati in rosso; il pannello inferiore mostra la curva del Matrix Profile con i minimi locali (Motifs) e i picchi massimi (Discords/Anomalie) chiaramente marcati.
- **Shapelet Alignment Plot ([shapelet_alignments/](#))**: Grafico a linee che mostra la serie temporale del driver esogeno con evidenziata in grassetto colorato la sezione in cui si è allineata la Shapelet predittiva, illustrando visivamente il "pattern precursore".
- **Dendrogrammi di Clustering Provinciale/Regionale Globale:**
- **Feature-Based Dendrogram ([dendrograms/global_regions_dendrogram_features.png](#))**: Dendrogramma basato su feature tsfresh ed algoritmo di legame Ward.
- **Shape-Based Dendrogram ([dendrograms/global_national_dendrogram_shape.png](#))**: Dendrogramma basato su allineamento dinamico DTW.
- **PCA Scatter Plot dei Cluster Spaziotemporali:**
- **Global PCA Scatter ([clustering/global_regions_pca_scatter.png](#))**: Dispersione bidimensionale dei cluster di province proiettati su spazio PCA.
- **Mappe Choropleth dei Cluster Nazionali e Regionali ([maps/global_national_map.png](#) / [maps/global_regions_map.png](#))**: Rappresentazione spaziotemporale geografica dei cluster funzionali per verificare la contiguità spaziale dei profili dinamici estratti.
- **Heatmap delle Distanze di Forma DTW ([heatmaps/global_national_dtw_heatmap.png](#))**: Matrice simmetrica $N \times N$ colorata con scala divergente (viridis) che mostra la distanza di allineamento temporale tra tutte le coppie di province.

Checklist di Sviluppo - FASE 3: Analisi Sequenziale ed Esplorazione Time Series

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 3**. L'obiettivo è analizzare le serie storiche dei driver per estrarne la stazionarietà, le anomalie e le feature dinamiche.

■ Task List

[] Task 3.1: Stazionarizzazione Automatica e Decomposizione STL

- **Descrizione:** Verificare e correggere la non-stazionarietà delle serie storiche prima della modellazione.
 - **Sotto-task:**
 - [] Implementare il test **Augmented Dickey-Fuller (ADF)** per la serie target (`phase_3plus_percentage`) e i driver esogeni a livello di provincia.
 - [] **Studio tramite ACF/PACF:** Calcolare e analizzare i correlogrammi iniziali. Se l'ACF mostra un decadimento lento e lineare (trend) o picchi periodici marcati (stagionalità), confermare la non-stazionarietà.
 - [] Sviluppare una routine di differenziazione automatica: applicare la differenza prima ($d=1$) o seconda ($d=2$) se il p-value del test ADF è ≥ 0.05 o l'autocorrelazione ne indica la necessità.
 - [] Applicare la decomposizione **STL (Seasonal-Trend Decomposition using LOESS)** per isolare trend, stagionalità e residui per ciascuna provincia. Salvare come `ML/results/time_series_exploration/01_Statistical_Decomposition_STL.png`.
 - [] Plottare e salvare i correlogrammi ACF/PACF finali delle serie stazionarizzate per verificare visivamente l'avvenuto riallineamento. Salvare come `ML/results/time_series_exploration/02b_Compare_Series_Autocorrelation.png`.
-

[] Task 3.2: Analisi di Cross-Correlazione con Lag (CCF)

- **Descrizione:** Calcolare i lag temporali ottimali dei driver esogeni rispetto al target IPC.
 - **Sotto-task:**
 - [] Implementare il calcolo della cross-correlazione per lag compresi tra -12 e $+12$ mesi.
 - [] Identificare per ciascuna provincia e driver il lag che presenta il valore assoluto di correlazione massimo.
 - [] Salvare i risultati in un file CSV ed esportare i grafici CCF (`ML/results/time_series_exploration/02c_Cross_Correlation_with_Target.png`).
-

[] Task 3.3: Anomaly Detection con Matrix Profile (Motifs & Discords)

- **Descrizione:** Cercare pattern ripetitivi (Motifs) e shock isolati (Discords) nelle serie esogene.

- **Sotto-task:**
 - [] Installare/importare librerie per il calcolo del Matrix Profile (es. `stumpy` o implementazione custom z-normalizzata).
 - [] Configurare una finestra temporale di $m = 12$ mesi.
 - [] Calcolare il Matrix Profile sui prezzi WFP e anomalie CHIRPS, individuando i Discords principali (shock di prezzo o climatici). Salvare come `ML/results/time_series_exploration/04_Matrix_Profile_Anomalies_Discords.png`.
 - [] Tracciare i residui dell'anomalia rispetto alla soglia $\$Z > 2.0\$$.
-

[] Task 3.4: Estrazione delle Shapelets Predittive

- **Descrizione:** Estrarre sottosequenze temporali discriminanti che precedono picchi di IPC3+.
 - **Sotto-task:**
 - [] Definire finestre temporali di input (es. 6 mesi di dati storici dei driver) associate a un picco dell'IPC3+ nei successivi 3 mesi.
 - [] Estrarre le Shapelets candidate usando algoritmi di shapelet discovery (es. `sktime.classification.shapelet_based.ShapeletTransformClassifier`).
 - [] Plottare l'allineamento delle shapelets e salvare le visualizzazioni in `ML/results/time_series_exploration/shapelet_alignments/`.
-

[] Task 3.5: Feature Extraction Strutturale via `tsfresh`

- **Descrizione:** Calcolare descrittori statici globali per sintetizzare le dinamiche delle serie storiche.
 - **Sotto-task:**
 - [] Configurare `tsfresh` per estrarre feature dalle serie storiche mensili provinciali.
 - [] Generare descrittori (media, varianza, Hurst exponent, entropia approssimata, coefficienti autoregressivi AR).
 - [] Applicare la feature selection integrata di `tsfresh` per filtrare solo le feature significativamente correlate al target IPC3+.
-

[] Task 3.6: Distanze Temporali e Clustering Dinamico (DTW & NCD)

- **Descrizione:** Calcolare le matrici di dissimilarità dinamica e raggruppare le province in base alla forma o comprimibilità delle loro serie storiche.
- **Sotto-task:**
- [] Sviluppare il calcolo della distanza **DTW (Dynamic Time Warping)** z-normalizzata tra le serie storiche provinciali. Esportare la heatmap delle distanze (`ML/results/time_series_exploration/heatmaps/global_national_dtw_heatmap.png`).

- [] Sviluppare il calcolo della distanza di compressione **NCD (Normalized Compression Distance)** concatenando e comprimendo i vettori delle serie storiche.
- [] Eseguire il clustering gerarchico sulle matrici di distanza risultanti. Salvare i dendrogrammi (`ML/results/time_series_exploration/dendrograms/global_regions_dendrogram_shape.png`) e i grafici scatter di PCA (`ML/results/time_series_exploration/clustering/global_regions_pca_scatter.png`).
- [] Mappare i cluster sulle province e salvare i plot geografici (`ML/results/time_series_exploration/maps/global_regions_map.png`).

FASE 4: Modellazione Temporale (Inferenza e Forecast su TS)

Task 4.1 - Classificazione delle Traiettorie Temporali (Weak Supervision)

- **Logica:** Invece di stimare un singolo timestamp, l'obiettivo qui è trovare una funzione matematica f che mappa lo spazio delle intere possibili serie temporali nello spazio di una classe finale target c_i .
 - **Applicazione:** La classe può indicare la "traiettoria di rischio" (es. Classe A: Deterioramento verso l'emergenza; Classe B: Stabilizzazione).
-

Task 4.2 - Forecast Time Series Indipendente (Univariato)

- **Modelli:** Modelli di base come l'Exponential Smoothing (ES) o gli ARIMA (AutoRegressive Integrated Moving Average).
 - **Ottimizzazione Parametri SARIMAX:**
 - Per modellare le componenti autoregressive (p , P), di media mobile (q , Q) e stagionali (s) a livello di singola provincia, si esegue una ricerca a griglia automatizzata (Grid Search, tipo *auto_arima*).
 - La scelta ottimale dei parametri viene effettuata minimizzando l'**AIC (Akaike Information Criterion)** per l'adeguatezza generale del fit ed il **BIC (Bayesian Information Criterion)** per penalizzare eccessive complessità ed evitare overfitting.
-

Task 4.3 - Forecast Multivariato su IPC (Modelli Causali e VAR)

- **Logica:** Valutare se includere altre variabili temporali riduca l'errore di forecast.
 - **Applicazione:** Usare algoritmi che catturano l'interdipendenza sequenziale multivariata (es. Vector Autoregression - VAR) per proiettare l'IPC tenendo in conto simultaneamente ACLED e Prezzi.
-

Task 4.4 - Diagnostica Avanzata e Distribuzione dei Residui dei Modelli

- **Logica:** Validare che i residui del modello di forecast migliore si comportino come "rumore bianco" (assenza di informazioni utili residue e assenza di autocorrelazione).
- **Metodologia & Analisi di Distribuzione:**

- Si analizza quantitativamente e visivamente la **distribuzione probabilistica dei residui** per verificarne la normalità (la media deve essere prossima a zero e la varianza costante, ovvero omoschedasticità).
- Il test di **Ljung-Box** viene applicato sui residui per testare l'ipotesi nulla di assenza di autocorrelazione per lag multipli.
- Se i residui presentano code spesse o skewness marcata, si valuta l'applicazione di trasformazioni logaritmiche sul target prima del fit.

Task 4.5 - Modellazione Ensemble tramite Stacking (Meta-Learning)

- **Logica (DMML)**: Integrare la precisione di modelli statistici lineari con la flessibilità di modelli non lineari di Machine Learning e Deep Learning per mitigare la varianza dell'errore.
- **Metodologia**: Le predizioni a livello provinciale di modelli univariati (ARIMA, ES), del VAR e del modello globale XGBoost verranno fornite in input a un modello di livello superiore (Meta-Regressore regolarizzato come Ridge o Lasso). Quest'ultimo imparerà i pesi ottimali da attribuire a ciascuna previsione per produrre un forecast consolidato finale.

■ Grafici e Visualizzazioni per la FASE 4

I grafici di questa fase devono essere archiviati nella directory **ML/results/temporal_modeling/** (con eventuali sotto-cartelle per provincia/paese):

- **Matrice di Confusione della Classificazione (confusion_matrices/)**: Mappa di calore delle predizioni vs valori reali per le classi di traiettoria (Escalation, Stabilità, Ripresa) per valutare errori sistematici di classificazione.
- **Grafico di Confronto Multi-Modello (05_MultiModel_Forecast_Comparison.png)**: Grafico temporale che confronta la serie storica reale (test set) con le proiezioni generate contemporaneamente da Holt-Winters, SARIMAX (ottimizzato AIC/BIC), Prophet e VAR, includendo una tabella sovrapposta con le metriche di errore calcolate (MAE, RMSE) per identificare visivamente il modello migliore.
- **Line plot di Forecast Univariato (forecasts/)**: Grafico temporale per province selezionate che mostra lo storico reale in linea continua nera, il fit del modello in linea tratteggiata blu e la proiezione futura con l'area semitrasparente che rappresenta l'intervallo di confidenza al 95%.
- **Impulse Response Function (IRF) Plot (var_irf/)**: Grafici a subplots derivati dal modello VAR. Mostrano come l'IPC3+ reagisca nel corso dei successivi 12 mesi a uno "shock" improvviso (impulso di una deviazione standard) applicato a un driver esogeno (es. un picco improvviso nei conflitti ACLED).
- **Model Residuals Diagnostics (4-Panel Plot - 06_Model_Residuals_Diagnostics.png)**:
 - Grafico a linee dei residui nel tempo per valutare l'omoschedasticità.
 - Istogramma con stima KDE della densità dei residui per verificarne la simmetria normale e studiarne la distribuzione probabilistica.
 - Q-Q Plot normale per valutare lo spessore delle code e la vicinanza alla gaussiana teorica.
 - Correlogramma ACF dei residui con limiti di confidenza del test di Ljung-Box.

- **Grafico delle Frazioni dei Pesi di Stacking (stacking_weights/):** Rappresentazione visiva dei pesi appresi dal meta-modello di stacking, mostrando l'importanza relativa di ciascun modello base (VAR, ARIMA, XGBoost) in base al territorio analizzato.

Checklist di Sviluppo - FASE 4: Modellazione Temporale (Forecasting)

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 4**. L'obiettivo è predire le traiettorie dell'IPC e il forecast quantitativo futuro sfruttando la componente autoregressiva e multivariata.

■ Task List

[] Task 4.1: Classificazione delle Traiettorie con Weak Supervision

- **Descrizione:** Categorizzare le serie storiche provinciali in traiettorie di rischio alimentare calcolando il delta dell'IPC.
- **Sotto-task:**
 - [] Definire la finestra temporale di valutazione (es. 12 mesi).
 - [] Calcolare il delta percentuale dell'IPC3+ ($\Delta = \text{IPC3}\%_{t+12} - \text{IPC3}\%_t$).
 - [] Assegnare le etichette di classe in base a regole fisse:
 - [] **Classe A (Escalation):** $\Delta \geq +15\%$
 - [] **Classe B (Stabilità):** $-5\% \leq \Delta \leq +5\%$
 - [] **Classe C (Recupero):** $\Delta \leq -15\%$
 - [] Addestrare un classificatore supervisionato (Random Forest / XGBoost) sulle feature storiche dei driver per prevedere l'appartenenza a queste classi.
 - [] Validare il modello calcolando la matrice di confusione in [ML/results/temporal_modeling/confusion_matrices/](#).

[] Task 4.2: Baseline di Forecast Univariato Indipendente (Risoluzione Nativa)

- **Descrizione:** Creare modelli indipendenti a livello di singola provincia/distretto (ADM1/ADM2) per stabilire la baseline di forecast.
- **Sotto-task:**
 - [] Configurare un ciclo iterativo su tutte le province/distretti del dataset.
 - [] Per ogni provincia, isolare la serie storica di `phase_3plus_percentage`.
 - [] Addestrare modelli univariati:
 - [] **Exponential Smoothing (Holt-Winters).**
 - [] **SARIMAX:** implementare una ricerca a griglia automatica per stimare i parametri autoregressivi, di stagionalità e media mobile (p, d, q, P, D, Q, s) minimizzando sia l'**AIC** (Akaike Information Criterion) sia il **BIC** (Bayesian Information Criterion).
 - [] Generare le previsioni out-of-sample per un orizzonte temporale $h=3$ e $h=6$ mesi.

- [] Salvare gli errori di previsione (MAE, RMSE) per il confronto finale ed esportare il grafico di confronto multimodello
([ML/results/temporal_modeling/05_MultiModel_Forecast_Comparison.png](#)).

[] Task 4.3: Forecast Multivariato Causale (VAR)

- **Descrizione:** Modellare l'interdipendenza tra target e driver esogeni.
- **Sotto-task:**
 - [] Assicurarsi che le serie storiche inserite siano stazionarie (Task 3.1).
 - [] Definire il vettore delle variabili: [\[IPC3+, acled_events_100k, wfp_price_index, ndvi_vim\]](#).
 - [] Inizializzare ed addestrare il modello **Vector Autoregression (VAR)** selezionando il lag ottimale tramite AIC.
 - [] Calcolare e tracciare le **Impulse Response Functions (IRF)** per simulare l'effetto a catena di uno shock improvviso dei driver sull'IPC3+. Salvare i plot in [ML/results/temporal_modeling/var_irf/](#).

[] Task 4.4: Diagnostica Avanzata e Distribuzione dei Residui

- **Descrizione:** Validare l'adeguatezza statistica del modello migliore verificando che i residui siano white noise e analizzandone la distribuzione.
- **Sotto-task:**
 - [] Estrarre i residui del modello predittivo migliore su una provincia test.
 - [] Analizzare la **distribuzione probabilistica dei residui**: verificare che abbiano media pari a zero, varianza costante (assenza di eteroschedasticità) e studiare l'istogramma/KDE per confermarne la simmetria normale.
 - [] Calcolare il test di **Ljung-Box** per verificare l'assenza di autocorrelazione residua significativa.
 - [] Generare e salvare il grafico diagnostico a 4 pannelli
([ML/results/temporal_modeling/06_Model_Residuals_Diagnostics.png](#)):
 - Residui nel tempo.
 - Istogramma + KDE dei residui vs curva normale per la distribuzione.
 - Q-Q plot normale.
 - Correlogramma ACF dei residui.

[] Task 4.5: Meta-Modello di Stacking Ensemble

- **Descrizione:** Sviluppare un modello di stacking che pesi le predizioni dei singoli regressori.
- **Sotto-task:**
 - [] Raccogliere le predizioni out-of-sample dei modelli univariati (ARIMA, ES), del VAR e del modello globale XGBoost.

- [] Addestrare un regressore lineare regolarizzato (**Ridge** o **Lasso**) avente come input le predizioni dei modelli base e come target il valore IPC3+ reale.
- [] Salvare i pesi risultanti del meta-modello in `ML/results/temporal_modeling/stacking_weights/` per illustrare il contributo relativo di ciascun algoritmo base.

FASE 5: Inferenza Cross-Regionale (Global Forecasting)

- **Metodologia:** Invece di addestrare modelli locali singoli per province con dati storici scarsi o frammentati, si sfrutta l'apprendimento globale basato sul clustering.
 - **Pipeline:**
 - Si applica il clustering spaziotemporale (DTW + tsfresh + coordinate standardizzate) per raggruppare le regioni in "archetipi di vulnerabilità".
 - Per ciascun cluster, si concatenano le serie storiche di tutte le province appartenenti ad esso.
 - Si addestra un unico modello di Machine Learning globale (XGBoost globale o rete neurale ricorrente LSTM/GRU) su tutti i dati del cluster.
 - Il modello globale generalizza il comportamento del cluster e può fare inferenza accurata anche su province che possiedono pochissimi dati storici (trasferimento di conoscenza spaziale).
-

Task 5.2 - Domain Adaptation & Trasferimento Spaziale (Transfer Learning)

- **Logica (DMML):** Testare la capacità del modello globale di generalizzare su territori privi di dati storici storicamente continui (es. a causa di embargo, conflitti intensi o interruzioni delle agenzie umanitarie).
 - **Metodologia:** Addestrare il modello globale su un sottoinsieme di paesi del cluster (es. Afghanistan e Somalia) e testarlo direttamente (Zero-Shot) o con fine-tuning leggero su paesi esclusi del medesimo cluster (es. Yemen), misurando la stabilità del trasferimento spaziale.
-

Task 5.3 - SHAP per Feature Temporal Strutturali (XAI Avanzata)

- **Logica (DMML):** Portare l'interpretabilità dei modelli ad un livello superiore. Invece di spiegare la previsione usando solo i valori puntuali correnti dei driver, si applicano gli additivi SHAP sull'output del modello globale addestrato sulle feature di `tsfresh`.
 - **Obiettivo:** Dimostrare quali pattern dinamici complessi (es. l'autocorrelazione a 3 mesi dei prezzi o la volatilità climatica dell'NDVI) abbiano guidato la predizione di crisi della provincia.
-

■ Grafici e Visualizzazioni per la FASE 5

- **Confronto Lineare Actual vs Predict (Global Model):** Grafici a linee multi-provincia in cui si sovrappongono i dati reali (linea nera) e le predizioni del modello globale (linea rossa tratteggiata) su un set di province "test" escluse dall'addestramento.

- **Scatter Plot dei Residui Globali:** Grafico a dispersione che mostra l'errore residuo del modello globale in funzione del tempo o della magnitudo del target, per verificare l'assenza di eteroschedasticità all'interno del cluster.
- **Beeswarm Plot SHAP delle Feature Temporal (**tsfresh** descriptors):** Visualizzazione SHAP che classifica l'impatto dei descrittori di serie storica (Hurst exponent, Fourier coefficients, ApEn, ecc.) sulle predizioni di carestia del modello globale.

Checklist di Sviluppo - FASE 5: Inferenza Cross-Regionale (Global Forecasting)

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 5**. L'obiettivo è addestrare modelli globali robusti aggregando i dati delle province dello stesso cluster e valutarne il trasferimento spaziale.

■ Task List

[] Task 5.1: Addestramento del Global Cluster Model

- **Descrizione:** Sviluppare e addestrare un singolo modello di ML potente concatenando le serie storiche delle province all'interno dello stesso cluster funzionale.
 - **Sotto-task:**
 - [] Recuperare le etichette di clustering spaziotemporale calcolate nella Fase 3 (DTW + tsfresh).
 - [] Per ogni cluster identificato, concatenare longitudinalmente le serie storiche (panel data) di tutte le province del cluster.
 - [] Creare le feature autoregressive ritardate (lag da 1 a 6 mesi per ciascun driver).
 - [] Addestrare un modello di **XGBoost / LightGBM Regressor** o una rete neurale ricorrente (**LSTM/GRU**) globale per il cluster specifico.
 - [] Misurare le performance predittive complessive del modello globale.
-

[] Task 5.2: Test di Domain Adaptation & Spatial Transfer Learning

- **Descrizione:** Valutare le capacità di generalizzazione spaziale del modello globale su aree escluse o prive di dati storici.
 - **Sotto-task:**
 - [] All'interno di un cluster, escludere un intero paese (es. lo Yemen) dal set di addestramento.
 - [] Addestrare il modello globale unicamente sui dati delle province dei restanti paesi del cluster (es. Somalia ed Etiopia).
 - [] Effettuare previsioni *Zero-Shot* sulle province del paese escluso (Yemen).
 - [] Effettuare previsioni applicando un *fine-tuning* leggero (ri-addestramento parziale del modello globale solo sulle prime 3 osservazioni del paese test).
 - [] Calcolare le metriche di errore e confrontare le due modalità (Zero-Shot vs Fine-Tuning) per quantificare la stabilità del trasferimento di conoscenza spaziale.
-

[] Task 5.3: Spiegabilità Temporale con SHAP (XAI)

- **Descrizione:** Applicare SHAP per identificare quali descrittori globali di serie storica guidano la predizione del modello globale.
- **Sotto-task:**
 - [] Creare la matrice delle feature strutturali (output di `tsfresh` selezionato) per le serie storiche del cluster.
 - [] Configurare `shap.TreeExplainer` sull'istanza del modello XGBoost globale addestrato.
 - [] Calcolare gli SHAP values per ciascuna provincia e data.
 - [] Generare e salvare il **Beeswarm Plot SHAP** specifico per le feature strutturali temporali (es. Hurst exponent, Fourier coefficients, ApEn).
 - [] Analizzare l'impatto delle componenti di trend e stagionalità rispetto alla varianza a breve termine dei prezzi e dei conflitti.
 - [] Salvare i risultati in `ML/results/global_forecasting/`.

FASE 6: Tecniche di Frontiera (Integrazione TSMDA & DMML)

1. Network Analysis Classica (NetworkX) e Autocorrelazione Spaziale

- **Rete di Integrazione dei Mercati (WFP):**
- **Concetto:** Rappresentare il sistema di scambio e distribuzione alimentare come una rete in cui i nodi sono i mercati fisici (o le province) e gli archi rappresentano la correlazione temporale dei prezzi dei beni alimentari di base.
- **Granularità Temporale:** Al fine di studiare l'integrazione e la propagazione degli shock con massima fedeltà e catturare i tempi di reazione (lags) rapidi dei mercati, **l'analisi di rete viene eseguita mantenendo la risoluzione temporale nativa non aggregata dei prezzi WFP** (es. frequenza settimanale o giornaliera originale), senza forzarli alla risoluzione mensile del target IPC.
- **Applicazione:** Utilizzo della libreria **NetworkX** per calcolare metriche di centralità (*Degree Centrality*, *Betweenness Centrality*). Questo consente di individuare empiricamente i mercati "hub" o di transito precisi che, se colpiti da uno shock sui prezzi, propagano l'inflazione alle aree adiacenti.
- **Autocorrelazione Spaziale (Moran's I & LISA):**
- **Concetto:** Verificare quantitativamente se la gravità dell'insicurezza alimentare di una provincia sia influenzata dalla vicinanza geografica con province colpite da crisi (effetto contagio).
- **Applicazione:** Calcolo dell'indice di Moran globale (*Moran's I*) per validare la presenza di autocorrelazione spaziale dell'IPC3+, e della mappa LISA (*Local Indicators of Spatial Association*) per identificare cluster spaziali di insicurezza (aree High-High o Low-Low).

2. Zero-Shot Forecasting con Foundation Models (TimesFM)

- **Concetto:** Applicazione del modello pre-addestrato di Google **TimesFM** per effettuare previsioni zero-shot sulle serie temporali IPC di territori privi di storico sufficiente.
- **Obiettivo:** Valutare se modelli generalisti pre-addestrati superano i modelli statistici tradizionali in contesti fragili.

3. Spatial Outlier Detection via DBSCAN

- **Metodologia:** Applicazione di DBSCAN sul dataset spaziotemporale delle feature strutturali.
- **Applicazione:** Identificare province atipiche (outliers/rumore per DBSCAN) che, pur trovandosi all'interno di una determinata area geografica colpita da crisi, mostrano dinamiche di resistenza o andamenti discordanti. Questo permette di isolare fattori di resilienza locale.

4. Clustering basato su Compressione NCD (Normalized Compression Distance)

- **Logica:** Clustering temporale alternativo al DTW basato sulla comprimibilità incrociata delle sequenze di dati.
 - **Applicazione:** Generare raggruppamenti di nazioni/regioni indipendentemente dalla scala o dal rumore geometrico.
-

■ Grafici e Visualizzazioni per la FASE 6

- **Grafo di Integrazione dei Mercati (NetworkX):** Rappresentazione visiva della rete dei mercati alimentari. I nodi hanno dimensioni proporzionali alla loro centralità (*Betweenness Centrality*) e gli archi hanno uno spessore proporzionale alla correlazione temporale dei prezzi, evidenziando le rotte principali di contagio economico.
- **Moran Scatterplot & Mappa LISA:** Grafico a dispersione che mostra la relazione tra il valore IPC3+ di una provincia e la media spaziale delle province confinanti. La mappa LISA colora le province evidenziando i cluster significativi (es. rosso per High-High, blu per Low-Low) e gli outlier spaziali.
- **TimesFM Zero-Shot Comparison Plot:** Grafico a linee che confronta la predizione a 6-12 mesi di TimesFM (senza addestramento locale) contro il reale andamento storico e contro la baseline locale ARIMA, per evidenziare visivamente la qualità del modello foundation.
- **DBSCAN Outlier Map/Scatter:** Grafico a dispersione PCA in cui i punti del rumore (outliers spaziali identificati da DBSCAN) sono colorati in rosso vivo su uno sfondo di cluster colorati in toni pastello, evidenziando geograficamente le anomalie di resilienza.
- **Heatmap delle Distanze di Compressione NCD:** Matrice simmetrica delle distanze basate sulla compressione delle stringhe/dati per visualizzare la dissimilarità globale.

Checklist di Sviluppo - FASE 6: Tecniche di Frontiera (TSMDA & DMML)

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 6**. L'obiettivo è implementare modelli e analisi avanzate (Network Analysis, TimesFM e DBSCAN) per arricchire il valore scientifico del progetto.

■ Task List

[] Task 6.1: Network Analysis Classica dei Mercati Alimentari (NetworkX)

- **Descrizione:** Rappresentare il sistema dei prezzi alimentari come una rete e calcolare le metriche di trasmissione degli shock.
- **Sotto-task:**
 - [] Filtrare i dati dei mercati WFP mantenendo la **risoluzione temporale nativa non aggregata** (es. settimanale o data transazione originale), evitando la contrazione a livello mensile **MS** per preservare i lag rapidi.
 - [] Calcolare la matrice di correlazione temporale dei prezzi tra tutte le coppie di mercati usando le serie storiche ad alta frequenza.
 - [] Costruire il grafo: i mercati sono i nodi; inserire un arco tra due nodi solo se il valore di correlazione supera una soglia definita (es. $r > 0.7$).
 - [] Utilizzare **NetworkX** per calcolare:
 - [] **Degree Centrality:** identificare i mercati più connessi.
 - [] **Betweenness Centrality:** identificare i mercati ponte che fungono da corridoi di trasmissione del rincaro dei prezzi.
- [] Salvare la struttura del grafo ed esportare il disegno della rete.

[] Task 6.2: Autocorrelazione Spaziale (Moran's I & LISA)

- **Descrizione:** Misurare formalmente l'effetto di vicinato e contagio geografico della crisi alimentare.
- **Sotto-task:**
 - [] Caricare i GeoJSON provinciali e allinearli al DataFrame dei dati IPC3+.
 - [] Calcolare la matrice dei pesi spaziali (contiguità Queen o Rook) usando la libreria **libpysal**.
 - [] Calcolare l'indice globale di **Moran's I** per testare la significatività dell'autocorrelazione spaziale dell'IPC3+ nel tempo.
 - [] Calcolare gli indicatori locali di associazione spaziale (**LISA**) per classificare ogni provincia in cluster spaziali significativi (High-High, Low-Low, High-Low, Low-High).
 - [] Salvare la mappa dei cluster LISA ed il Moran Scatterplot.

[] Task 6.3: Zero-Shot Forecasting con TimesFM (Google Foundation Model)

- **Descrizione:** Testare il modello pre-addestrato di Google per il forecast out-of-sample senza addestramento locale.
- **Sotto-task:**
 - [] Installare e configurare l'ambiente di runtime per **TimesFM**.
 - [] Caricare le serie storiche IPC3+ provinciali e formattarle secondo i requisiti di TimesFM (input length, context length, horizon).
 - [] Invocare TimesFM in modalità *Zero-Shot* per generare previsioni a 6 mesi.
 - [] Calcolare gli errori di forecast (MAE, RMSE) sul test set.

[] Task 6.4: Spatial Outlier Detection via DBSCAN

- **Descrizione:** Isolare anomalie di resilienza geografica identificando province con dinamiche atipiche rispetto al loro vicinato.
- **Sotto-task:**
 - [] Costruire la matrice delle feature aggregando le coordinate lat/lon standardizzate e i descrittori delle serie storiche (tsfresh).
 - [] Inizializzare ed applicare **DBSCAN** impostando opportunamente i parametri **eps** e **min_samples**.
 - [] Identificare i punti classificati come rumore/outliers (\$label = -1\$).
 - [] Mappare geograficamente questi outliers per individuare le province che mostrano andamenti discordanti (es. province resilienti pur circondate da siccità o guerra).
 - [] Salvare i risultati in **ML/results/frontier_techniques/**.

FASE 7: A/B Testing e Benchmarking

Sperimentale

Tutte le metodologie saranno valutate calcolando metriche di errore di previsione (MAE, RMSE, MAP) su un test set comune:

Dimensione di Analisi	Modello A (Baseline)	Modello B (Sfidante)	Ipotesi da Verificare
Preprocessing	Dataset Raw con NaNs (gestito da XGBoost)	Dataset imputato con <code>impute_missing_knn_geo</code> all'omissione y	L'imputazione spaziale riduce l'errore di forecast rispetto alla gestione nativa del dato mancante.
Sequenzialità	Modello Statico Cross-Section (Fase 2)	Modello Temporale Univariato/Multivariato (Fase 4)	L'inclusione di feature dinamiche e lag storici abbatta significativamente i tassi di errore.
Geometria di Rete	Forecast Locale per singola provincia	Forecast Globale di Cluster (Fase 5)	L'inferenza cross-regionale aggregata su base cluster migliora l'accuratezza nei territori poveri di dati.

■ Grafici e Visualizzazioni per la FASE 7

- Bar Chart Multiasse degli Errori:** Grafico a barre raggruppate che mette a confronto le metriche MAE e RMSE per i vari modelli (Statico, ARIMA, VAR, Modello Globale con/senza coordinate, TimesFM) per identificare visivamente il modello migliore.
- Radar Chart delle Performance:** Grafico a radar (spider plot) in cui le diverse dimensioni rappresentano criteri di valutazione qualitativa e quantitativa (es. accuratezza a breve termine, accuratezza a lungo termine, costo computazionale di calcolo, interpretabilità del modello, resilienza ai dati mancanti). Ogni modello è tracciato come un'area colorata coprente.

Checklist di Sviluppo - FASE 7: A/B Testing e Benchmarking Sperimentale

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 7**. L'obiettivo è validare scientificamente le scelte metodologiche del progetto confrontando i modelli lungo tre assi di testing.

■ Task List

[] Task 7.1: Calcolo Comparativo delle Metriche (Il Framework di Test)

- **Descrizione:** Calcolare in modo uniforme gli errori di forecast su un test set comune e non contaminato per tutti i modelli sviluppati.
- **Sotto-task:**
 - [] Isolare la finestra di test temporale (es. gli ultimi 6 mesi storici disponibili del dataset).
 - [] Sviluppare una funzione centralizzata per il calcolo di:
 - Mean Absolute Error (MAE): $\text{MAE} = \frac{1}{N} \sum |y_i - \hat{y}_i|$
 - Root Mean Squared Error (RMSE): $\text{RMSE} = \sqrt{\frac{1}{N} \sum (y_i - \hat{y}_i)^2}$
 - Mean Absolute Percentage Error (MAPE): $\text{MAPE} = \frac{1}{N} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$
 - [] Popolare la tabella comparativa per i seguenti tre assi di test:
 - [] **Test A (Preprocessing):** Dataset Raw (senza imputazione, gestito nativamente da XGBoost) vs Dataset imputato spazialmente con KNN.
 - [] **Test B (Sequenzialità):** Modello statico Fase 2 vs Modelli temporali (VAR, ARIMA) vs Modello spazio-temporale (VAR/XGBoost con coordinate).
 - [] **Test C (Integrazione di Rete):** Previsione locale (univariata ARIMA/ES) vs Previsione globale di cluster (Fase 5) vs Stacking Ensemble.

[] Task 7.2: Visualizzazione del Benchmarking

- **Descrizione:** Produrre grafici sintetici per illustrare chiaramente le performance dei modelli.
- **Sotto-task:**
 - [] Generare e salvare il **Bar Chart Multiasse** per visualizzare MAE e RMSE affiancati per ciascun modello base ed ensemble.
 - [] Generare e salvare il **Radar Chart** (spider plot) per confrontare i modelli su dimensioni multiple (accuratezza a breve termine, accuratezza a lungo termine, costo computazionale, interpretabilità, stabilità ai dati mancanti).
 - [] Salvare la tabella riassuntiva finale in formato CSV e Markdown in [ML/results/benchmarking/](#).

FASE 8: Visualizzazione Interattiva (Data Visual Analytics)

L'output del progetto include un'applicazione di dashboard web interattiva e visualizzazione geospaziale avanzata che rispecchia l'esatta struttura dei componenti attivi nella UI:

1. Visualizzazione Geospaziale e Cartografia Digitale (Folium & GeoPandas)

- **Choropleth Map Animata:** Mappa interattiva a livello Admin 1 (provinciale) e Admin 2 (distrettuale) colorata in base alla percentuale `phase_3plus_percentage`, controllata da uno slider temporale per visualizzare l'evoluzione e la propagazione geografica della crisi.
 - **Marker geografici di Shock:** Puntatori posizionati sui centroidi delle province in cui il Matrix Profile rileva shock sistemici superati la soglia $\$Z > 2.0\$$ (Discord).
-

2. Tabella di Macro-Confronto (Heatmap Matrix con ApexCharts)

- **Heatmap dei Paesi e delle Province:** Tabella interattiva a doppia entrata (Paese/Provincia vs Tempo) in ApexCharts che permette il drill-down sul livello di insicurezza alimentare globale ed evidenzia i territori più critici a colpo d'occhio.
-

3. Pannello Principale dei Trend Temporali (Cartesiano/Lineare)

Grafici a linee/area cartesiani interattivi con asse temporale continuo (`app.js` references): * **Fasi IPC (`chart-ipc`):** Andamento della percentuale della popolazione ripartita per ciascuna delle 5 classi IPC nel tempo. * **Conflitti ACLED (`chart-acled`):** Grafico a linee multi-variabile per tracciare contemporaneamente la frequenza degli eventi e il numero delle vittime per tipologia (political violence, civilian targeting, demonstrations). * **Sfollati IDP (`chart-idp`):** Curva della popolazione sfollata interna registrata nel tempo. * **Precipitazioni CHIRPS (`chart-rainfall` - Dual Axis):** Barre verticali indicanti le piogge accumulate mensili e linea sovrapposta indicante l'anomalia climatica rispetto allo storico. * **Mercati Alimentari WFP (`chart-wfp`):** Line plot dei prezzi medi ponderati e dei tassi inflazionistici mensili. * **Vigore Vegetativo NDVI (`chart-ndvi` - Dual Axis):** Curva del vigore vegetativo medio (`ndvi_vim`) e della qualità vegetativa (`ndvi_viq`) per monitorare la siccità agricola. * **Sentiment Media GDELT (`chart-gdelt`):** Trend delle notizie giornalistiche indicizzate per QuadClass di conflitto/cooperazione verbale e materiale.

4. Pannello dei Profili Stagionali (12 Radar/Circular Charts Sincronizzati)

- **Radar a 4 Vertici (Trimestrali - Q1, Q2, Q3, Q4)** con colorazione a gradienti.

- **Interazione e Hover Sincronizzato:** Cliccando o passando il mouse su un determinato quarto (es. Q3) in uno dei 12 indicatori (es. `chart-rainfall-rain-seasonal`), tutti gli altri 11 grafici radar stagionali (IPC, prezzi, NDVI, conflitti, ecc.) evidenziano istantaneamente lo stesso quarto. Questo permette agli analisti di identificare visivamente la latenza stagionale e le relazioni tra anomalie delle piogge e conseguente impennata dell'IPC o dei conflitti nello stesso trimestre o in quelli successivi.

5. Sotto-View dei Mercati Alimentari Locali (WFP Market Charts)

- **Dettaglio Prezzi ed Inflazione:** Grafici dedicati (`chart-market-price-index` e `chart-market-inflation`) per visualizzare l'andamento dei prezzi dei singoli mercati all'interno della provincia selezionata.

6. Pannello GDELT Avanzato (Tone & Salience)

- **Analisi dei Media:** Grafici interattivi (`chart-gdelt-tab-tone` e `chart-gdelt-tab-salience`) focalizzati esclusivamente sul sentiment giornalistico complessivo del paese (Tone) e sul volume globale di notizie prodotte (Salience).

7. Pannello di Confronto Dati Grezzi vs Processati (Diagnostics)

- **Visualizzazione Preprocessing:** Grafico comparativo (`chart-compare`) che mostra la sovrapposizione tra la serie temporale originale contenente i dati grezzi con vuoti e NaN (raw data) e la corrispondente serie ricostruita/imputata spaziotemporalmente, per monitorare la fedeltà del preprocessing.

8. Pannello di Simulazione e Analisi di Scenario ("What-If" Analysis)

- **Simulazione Causalità Dinamica:** Integrazione di cursori interattivi (slider) associati a ciascun driver (es. simulazione di una riduzione del 30% dell'NDVI o un incremento di eventi ACLED). Cliccando sul pulsante "Simula Shock", l'interfaccia invocherà i coefficienti del modello VAR per tracciare in tempo reale la propagazione temporale teorica dello shock simulato sull'IPC3+ della provincia selezionata per i successivi 6 mesi.

■ Grafici e Visualizzazioni per la FASE 8 (Layout Interattivo)

- **Linked Scatter + Line Plot (Altair):** Cliccando su una provincia nella mappa geospaziale Folium (o in un grafico a dispersione PCA dei cluster), una seconda serie temporale Altair adiacente si aggiorna istantaneamente mostrando la "Crisis Timeline" di quel territorio specifico.

- **Time-Series Horizon Chart:** Grafico a bande di colore sovrapposte (Horizon Chart) per visualizzare simultaneamente l'andamento di decine di province su una singola pagina senza affollamento visivo, facilitando il confronto visivo di trend divergenti.
- **Visualizzatore Interattivo "What-If" (Altair / D3):** Grafico temporale con due linee: una linea continua che mostra la proiezione di base (baseline forecast) e una linea tratteggiata rossa dinamica che mostra la traiettoria IPC3+ simulata dall'utente manipolando gli slider dei driver di siccità e conflitto.

Checklist di Sviluppo - FASE 8: Visualizzazione Interattiva (Data Visual Analytics)

Questo documento contiene i dettagli implementativi e la checklist per la **Fase 8**. L'obiettivo è realizzare la dashboard web interattiva per l'esplorazione cartografica, temporale, stagionale e di scenario (What-If) basata su Folium, Altair e ApexCharts.

■ Task List

[] Task 8.1: Cartografia Digitale Geospaziale (Folium)

- **Descrizione:** Realizzare la mappa choropleth interattiva con controllo temporale e marker degli shock.
 - **Sotto-task:**
 - [] Caricare i dati geografici provinciali/distrettuali (GeoJSON) ed allinearli al dataset IPC.
 - [] Inizializzare la mappa Folium centrata sull'area di studio.
 - [] Creare la choropleth map colorata secondo il target `phase_3plus_percentage`.
 - [] Implementare il plugin `TimeSliderChoropleth` per consentire lo scorrimento temporale mese per mese.
 - [] Aggiungere marker sui centroidi delle province colpite da anomalie significative (Z-score del Matrix Profile > 2.0).
-

[] Task 8.2: Tabella Macro-Confronto (ApexCharts Heatmap Matrix)

- **Descrizione:** Configurare la matrice globale per il monitoraggio.
 - **Sotto-task:**
 - [] Preparare il dataset aggregato (Paese/Provincia vs Date).
 - [] Configurare ApexCharts in Javascript (`app.js`) per caricare la heatmap.
 - [] Implementare il callback `dataPointSelection` per fare in modo che, al clic su una cella (es. una provincia in una determinata data), il resto della dashboard mostri i dettagli di quella provincia.
-

[] Task 8.3: Trend Cartesiani e Toggles del Layout (Linear vs Circular)

- **Descrizione:** Sviluppare i grafici di trend e il toggle di coordinate.
- **Sotto-task:**
 - [] Implementare i trend cartesiani per IPC, ACLED, IDP, Rainfall (dual axis), WFP, NDVI (dual axis) e GDELT.
 - [] Sviluppare l'interruttore logico `chart-layout-toggle-group`.

- [] Configurare la conversione dinamica: se impostato su "circular/radar", distruggere i grafici cartesiani e rigenerare i grafici a radar (polari) che riassumono la stagionalità o i descrittori strutturali della provincia.

[] Task 8.4: Profili Stagionali con Radar Sincronizzati

- **Descrizione:** Implementare i 12 grafici a radar con evidenziazione coordinata del trimestre.
- **Sotto-task:**
 - [] Raggruppare i dati storici per trimestre (Q1, Q2, Q3, Q4) e per anno per tutti i 12 indicatori seasonal.
 - [] Generare i 12 grafici a radar ApexCharts con colorazione a gradienti.
 - [] Sviluppare la funzione Javascript `highlightMarkerInAllSeasonalCharts(qIndex)` per intercettare l'hover sul trimestre \$\$ di uno qualsiasi dei radar ed applicare la classe di highlight sullo stesso trimestre in tutti gli altri 11 grafici.
 - [] Sviluppare `clearHighlightInAllSeasonalCharts()` al mouseout.

[] Task 8.5: Simulatore di Scenario ("What-If" Analysis)

- **Descrizione:** Realizzare l'interfaccia di simulazione causale.
- **Sotto-task:**
 - [] Creare gli slider HTML per controllare le variazioni percentuali fittizie dei driver (NDVI, ACLED, prezzi WFP).
 - [] Inserire il pulsante "Simula Shock".
 - [] Sviluppare la logica in `app.js` che, al clic, moltiplica l'input per i coefficienti del modello VAR appresi per tracciare la risposta impulsiva simulata dell'IPC3+ per i successivi 6 mesi.
 - [] Rappresentare graficamente la traiettoria simulata (linea tratteggiata rossa) sovrapposta alla proiezione di base (linea blu).
 - [] Salvare i file in `UI/` ed eseguire i test locali.

